

南开大学
Nankai University

南　　开　　大　　学

密 码 与 网 络 空 间 安 全 学 院

自然语言处理实验报告

作业一：文本分类实现

彭湃

学号 ： 2311688

年级：2023 级

专业：信息安全、法学双学位班

指导教师：曾庆锴

2026 年 10 月 10 日

目录

一、 实验目标 **1**

二、 实验原理与实现 **1**

（一） 数据集与实验设置 1

（二） Task1：Bag of Words 1

（三） Task2：Word2Vec 2

（四） Task3：Pre-trained Neural Models 2

三、 实验结果与分析 **3**

（一） 全部实验测试集结果汇总 3

（二） Bag of Words 模型实验分析 3

（三） 不同 word embedding 方案对比分析 3

（四） BERT 微调实验分析 3

四、 实验存在的问题与局限性 **4**

五、 实验总结 **4**

六、 附录：代码与提交说明 **4**

一、 实验目标

本次作业旨在理解和掌握不同文本表示方法在文本分类任务中的基本原理与实际效果。分别使用传统词袋模型、Word Embedding/Word2Vec，以及预训练语言模型对文本进行表示，并训练文本分类模型。

- 理解不同文本表示方法的基本思想
- 掌握文本分类任务的基本实验流程
- 熟悉 Logistic Regression 在文本分类中的使用
- 掌握 Word2Vec、GloVe 等词向量的基本使用方法
- 熟悉 BERT 类预训练语言模型的 Fine-tuning 流程
- 能够使用 Accuracy 和 Macro-F1 对文本分类模型进行评价
- 能够对不同文本表示方法的性能进行基本比较和分析

二、 实验原理与实现

实验使用 NYT 新闻数据集作为主数据集，分为 sports、business、politics 三个类别；AG News 数据集仅用于训练 Word2Vec 词向量。数据集按照 80% 训练集、10% 验证集、10% 测试集划分，固定随机种子保证可复现。所有超参数调优仅使用验证集，测试集只用来输出最终指标，不参与任何训练、建表、调参过程。

(一) 数据集与实验设置

- NYT 数据集：包含新闻文本字段与类别标签，预处理后得到清洗文本 `text_clean` 和分词列表 `tokens`。
- AG News 数据集：仅用于训练 Word2Vec 词向量，不参与分类任务。
- 划分方式：分层随机划分，训练集 80%、验证集 10%、测试集 10%，固定 `random_state=42`，保证各子集类别分布与原数据集保持一致。
- 分词工具：NLTK`word_tokenize`，统一完成全部文本分词。

防止数据泄露约束：

1. 词表仅由训练集构建；
2. 训练 NYT 版 Word2Vec 时，只使用训练集文本，验证集、测试集完全不参与词向量训练；
3. 验证集、测试集只执行 transform，不参与 fit、fit_transform 过程。

(二) Task1：Bag of Words

Bag of Words 将文档映射为词表维度的高维稀疏向量，丢弃词序、句法信息，只统计文档内单词出现情况，分类器统一使用 Logistic Regression。

Binary Bag of Words 向量每一维取 0 或 1。若单词在文档中出现则置为 1，否则为 0。仅记录单词是否出现，不统计出现频次。

Word Frequency Bag of Words 向量每一维存储对应单词在文档中的原始出现次数，向量表示为 $\boldsymbol{x} = (c_1, c_2, ..., c_{|V|})$，$c_i$ 为第 i 个词的出现次数。

实现细节 使用 `CountVectorizer` 完成向量化。仅对训练集执行 `fit_transform` 构建词表；验证集、测试集只调用 `transform`。逻辑回归正则超参数 C 遍历集合 $[0.01, 0.1, 1.0, 10.0]$，依据验证集 Macro-F1 选出最优 C，再在测试集上评估最终指标。

(三) Task2：Word2Vec

word embedding 将单词映射为低维稠密 word vector，本实验全部 word vector 统一为 100 维。文档向量由文档内全部有效 word vector 算术平均得到：

$$\boldsymbol{e}(d) = \frac{1}{n} \sum_{i=1}^{n} \boldsymbol{e}(w_i)$$

其中：

- n：文档中命中 word vector 表的单词数量；
- 未登录 OOV 单词直接跳过；
- 若全部单词均未命中词表，则文档向量填充全零向量。

三组 word embedding 实验：

1. **Pre-trained GloVe(`glove.6B.100d`)**：读取本地 txt 文件加载斯坦福预训练 word vector，该 vector 在大规模通用文本上训练，具备通用语义知识。
2. **基于 AG News 训练 Word2Vec**：Gensim 训练，窗口 `window=5`，低频过滤 `min_count=2`，使用 AG News 全部文本训练 word vector，迁移至 NYT 分类任务。
3. **基于 NYT 训练集训练 Word2Vec**：仅使用 NYT 训练集分词结果训练，验证集、测试集文本不参与 word vector 训练，避免数据泄露。

得到稠密文档向量后送入逻辑回归，在验证集搜索最优正则系数 C，测试集输出结果。

(四) Task3：Pre-trained Neural Models

使用 `google-bert/bert-base-uncased` 完成三分类端到端微调，参数设置为：

- 最大序列长度 `max_length=64`，超长截断、不足补 padding；
- 训练 epoch 固定为 3 轮；
- 在 BERT 编码器上层新增分类头，整体微调，不额外接入逻辑回归。

实现基于 HuggingFace `Trainer` API。本地 CPU 训练耗时巨大，因此在 Kaggle GPU T4 完成训练。云端临时修改文件读取路径，源代码保持了本地路径。训练每轮结束在验证集评估，开启 `load_best_model_at_end` 保存验证集最优模型，最终使用测试集评估。

NKU

三、 实验结果与分析

(一) 全部实验测试集结果汇总

所有指标均来自 NYT 独立测试集。

表 1: 各方法在 NYT 测试集上的实验结果

任务	实验方法	Accuracy	Macro-F1
Task1	Binary_BoW	0.9905	0.9764
Task1	Word_Frequency_BoW	0.9896	0.9742
Task2	GloVe_6B_100d	0.9844	0.9623
Task2	Word2Vec_AGNews	0.9783	0.9482
Task2	Word2Vec_NYTtrain	0.9818	0.9533
Task3	BERT_base_uncased	0.9835	0.9604

(二) Bag of Words 模型实验分析

Binary Bag-of-Words 综合表现略优于 Word-Frequency Bag-of-Words。说明在该新闻三分类任务中，**单词是否出现已经携带绝大部分判别信息，单纯统计出现次数几乎无法带来额外增益**。

数据集 sports 类别占比约 75%，存在明显类别不平衡。两组 Bag-of-Words 模型 Macro-F1 均保持 0.97 以上，说明模型对 business、politics 少数类别同样识别效果良好，不会简单偏向多数类。

Bag-of-Words 存在固有缺陷：完全丢弃词序、句法，无法区分多义词、理解否定语义。但本任务分类高度依赖主题关键词，Bag-of-Words 的缺陷没有对任务性能造成明显负面影响。

(三) 不同 word embedding 方案对比分析

word embedding 组整体性能低于 Bag-of-Words 模型,内部性能排序:GloVe > Word2Vec_NYTtrain > Word2Vec_AGNews。

1. GloVe 预训练 word vector 效果最优：在数十亿规模通用文本训练，词表覆盖广，单词语义表示质量更高。
2. NYT 训练集训练的 Word2Vec：训练语料与下游任务属于同一新闻领域，但训练文档数量少，word vector 质量受限，因此弱于 GloVe，优于 AG News 训练得到的 vector。
3. AG News 训练的 Word2Vec：文档数量多，但全部为短新闻片段，上下文分布与长文本 NYT 新闻差异较大，迁移效果最差。

另外，本实验文档向量采用简单 word vector 算术平均，该池化操作丢失句子顺序与局部上下文信息，也是 word embedding 组整体弱于稀疏 Bag-of-Words 的重要原因。

(四) BERT 微调实验分析

BERT 具备强大的上下文语义建模能力，但本实验设置 `max_length=64`。NYT 新闻多为长文本，绝大多数样本会被截断；部分决定类别的关键词落在截断位置之后，模型无法读取，直接限制 BERT 的性能潜力。

受截断约束的前提下，BERT 依然取得和 GloVe 接近的结果。但 Bag-of-Words 可以获取整篇文档全部词汇特征，因此 BERT 没有超过 Bag-of-Words。该现象说明：深度学习模型并不必然优于传统方法，任务特性、文本长度会极大影响最终性能。

四、 实验存在的问题与局限性

1. **单一数据划分**：仅使用 `seed=42` 一套划分，无法评估不同随机划分带来的性能波动；多次重复实验取平均值会更加严谨。
2. **BERT 序列长度限制**：实验固定 `max_length=64`，长文本大量信息被截断；调大序列长度，BERT 指标存在进一步提升空间。
3. **自训练 Word2Vec 语料规模小**：NYT 训练集文档数量有限，训练得到的 word vector 对低频词表达能力不足。
4. **仅在 NYT 数据集验证**：本实验得到的模型优劣顺序，只适用于该新闻三分类任务，不能直接推广到其他领域。
5. **数据集类别不均衡**：sports 样本占比过高；Macro-F1 缓解评价偏差，但原始训练分布依然会影响模型学习过程。

五、 实验总结

本次实验完整完成三类文本表示方法的文本分类实验，严格执行数据泄露规避规范：词表构建、word vector 训练、超参调优全程不使用测试集。

针对 NYT 新闻三分类任务，Binary Bag of Words 取得最优效果，关键词的出现与否是主要分类信号，词频统计提升有限。word embedding 方法中，大规模外部预训练 GloVe 优于小规模语料自训练 Word2Vec；同领域小语料训练的 word vector，迁移表现优于异域短文本语料训练结果。BERT 能力强大，但受固定短序列截断约束，性能未能超过传统 Bag of Words。

通过实验可以直观体会不同文本表示的优缺点：Bag of Words 可以保留关键词信号，但丢失语义和顺序；word embedding 得到稠密语义表示，但简单平均池化会损失序列信息；BERT 可以建模上下文，但对输入文本长度十分敏感。模型好坏需要结合数据集与任务场景综合判断，不能盲目认为深度模型一定最优。

六、 附录：代码与提交说明

全部代码托管至 GitHub。提交内容包含全部`.py` 源代码、`requirements.txt`、`README.md` 以及输出 csv 结果文件。

- `data_preprocess.py`：数据读取、清洗、分词、分层划分数据集；
- `run_bow.py`：Task1 两组 Bag of Words 运行脚本；
- `run_w2v.py`：Task2 三组 word embedding 运行脚本；
- `run_bert.py`：Task3 BERT 微调脚本；
- `results/*.csv`：各个任务测试集输出指标。